



**AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE**

**WYDZIAŁ INFORMATYKI, ELEKTRONIKI I TELEKOMUNIKACJI**

**INSTYTUT INFORMATYKI**

## **PRACA DYPLOMOWA MAGISTERSKA**

*Ocena jakości i parametrów mechanicznych odlewów przy użyciu  
metod uczenia maszynowego*

*Casting quality and mechanical parameters prediction using machine learning methods*

Autor:	<i>Wiktor Reczek</i>
Kierunek studiów:	<i>Informatyka</i>
Typ studiów:	<i>Stacjonarne</i>
Opiekun pracy:	<i>prof. dr hab. Bartłomiej Śnieżyński</i>

Kraków, 2021

*Uprzedzony o odpowiedzialności karnej na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.): „Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystycznego wykonania albo publicznie zniekształca taki utwór, artystyczne wykonanie, fonogram, wideogram lub nadanie.”, a także uprzedzony o odpowiedzialności dyscyplinarnej na podstawie art. 211 ust. 1 ustawy z dnia 27 lipca 2005 r. Prawo o szkolnictwie wyższym (t.j. Dz. U. z 2012 r. poz. 572, z późn. zm.): „Za naruszenie przepisów obowiązujących w uczelni oraz za czyny uchybiające godności studenta student ponosi odpowiedzialność dyscyplinarną przed komisją dyscyplinarną albo przed sądem koleżeńskim samorządu studenckiego, zwanym dalej «sądem koleżeńskim».”, oświadczam, że niniejszą pracę dyplomową wykonałem(-am) osobiście i samodzielnie i że nie korzystałem(-am) ze źródeł innych niż wymienione w pracy.*

*Serdecznie dziękuję ... tu ciąg dalszych podziękowań np. dla promotora, żony, sąsiada itp.*



## Spis treści

<b>1. Wstęp</b>	9
1.1. Wprowadzenie	9
1.2. Cel i zakres pracy	9
1.3. Zawartość pracy	10
<b>2. Stan badań</b>	11
2.1. Powiązane prace – zarys historyczny	11
2.1.1. Predykcja wartości liczby ferrytowej	11
2.1.2. Predykcja własności mechanicznych odlewów	13
<b>3. Przykłady elementów pracy dyplomowej</b>	17
3.1. Liczba	17
3.2. Rysunek	17
3.3. Tabela	17
3.4. Wzory matematyczne	18
<b>4. Przykłady elementów pracy dyplomowej</b>	19
4.1. Liczba	19
4.2. Rysunek	19
4.3. Tabela	19
4.4. Wzory matematyczne	20
<b>5. Przykłady elementów pracy dyplomowej</b>	21
5.1. Liczba	21
5.2. Rysunek	21
5.3. Tabela	21
5.4. Wzory matematyczne	22
<b>6. Przykłady elementów pracy dyplomowej</b>	23
6.1. Liczba	23
6.2. Rysunek	23
6.3. Tabela	23

6.4. Wzory matematyczne .....	24
-------------------------------	----

## Streszczenie pracy

Celem niniejszej pracy jest zbadanie skuteczności różnych algorytmów klasyfikacji i ich rozszerzeń w ocenie jakości odlewów. Pomocne w realizacji projektu może być opracowanie oprogramowania pozwalającego na kompleksowe przebadanie wszystkich zaimplementowanych algorytmów. Korzystając z tej aplikacji, zostaną przeprowadzone eksperymenty, w których przygotowane oprogramowanie zostanie przetestowane w różnych warunkach i konfiguracjach, a także dla różnych algorytmów oraz danych wejściowych, którymi są zdjęcia przekrojów odlewów (zdjęcia mikrostruktury) lub informacje na temat materiału (np. typ, skład).

Praca ma charakter badawczy, gdyż jak wykazał przegląd literatury, prac naukowych na ten temat (tj. pod kątem wykorzystania uczenia maszynowego w celu oceny jakości odlewów) oraz źródeł wskazujących na praktyczne stosowanie oprogramowania o podobnym przeznaczeniu jest niewiele. Dlatego też możliwości wykorzystania uczenia maszynowego do oceny jakości odlewów będą przetestowane z użyciem najbardziej uniwersalnych metod, a także zostaną porównane te wyniki z rezultatami sieci neuronowych.

## Abstract of master's thesis

The aim of this research is to see how efficient various categorization algorithms and extensions are at determining casting quality. The development of software that allows for extensive testing of all developed algorithms could be beneficial to the project's implementation. Experiments will be conducted using this application, in which the developed software will be tested in a variety of situations and configurations, as well as for a variety of algorithms and input data, such as images of casting sections (pictures of microstructure) or material information (e.g., type, composition).

Because there are few scholarly articles on the issue (i.e., using machine learning to assess the quality of castings) and few sources suggesting the actual usage of software for comparable reasons, the work is of a research character. As a consequence, the capabilities of utilizing machine learning to assess the quality of castings will be explored using the most general approaches, with the results compared to neural networks.





# 1. Wstęp

## 1.1. Wprowadzenie

Człowiek od zawsze starał się maksymalnie upraszczać swoje życie. W czasach pradawnych wiązało się to z konstrukcją coraz to bardziej skomplikowanych przyrządów, początkowo prymitywnych technicznie. W miarę postępu człowiek był już w stanie opracowywać bardziej zaawansowane narzędzia. Obecnie, na bardzo długiej osi rozwoju ludzkości znajdujemy się w miejscu, gdzie większość postępu jest związana z odkryciami naukowymi w takich dziedzinach, jak fizyka, chemia, biologia czy informatyka. W tej ostatniej szczególnie dużo się dzieje, a to za sprawą m.in. uczenia maszynowego, czy szerzej, sztucznej inteligencji (SI). Wbrew pozorom nie jest to dziedzina całkiem nowa, gdyż jej początki sięgają lat 50. XX wieku, natomiast znaczące przyspieszenie rozwoju w tej dziedzinie nastąpiło dopiero w ostatnich kilkunastu latach, a to ze względu na coraz większą ilość produkowanych danych oraz możliwość ich szybkiego przetworzenia (szybsze procesory). Aktualnie postęp w sztucznej inteligencji jest na takim etapie, że wiele zadań przez nią wykonywanych jest lepiej, niż przez ludzi (tzw. osiągnięcia nadludzkie); wiele zadań jest też wykonywanych na poziomie mistrzowskim. Dlatego panuje obecnie trend, aby jak najwięcej czynności zautomatyzować, czy też wykonywać za pomocą sztucznej inteligencji. Stąd zapewne pojawił się pomysł, aby wykorzystać ją do kolejnego zadania, jakim jest klasyfikacja jakości odlewów.

Zdjęcia mikrostruktury metali dla osoby bez specjalistycznej wiedzy wyglądają niemal identycznie. Obecnie wykorzystuje się m.in. badania niszczące w celu określenia parametrów mechanicznych odlewów. Rozwiązanie przedstawione w tej pracy pozwoliłoby zaoszczędzić środki za zużyte materiały, a także czas potrzebny na „ręczne” zidentyfikowanie jakości odlewu.

## 1.2. Cel i zakres pracy

Celem niniejszej pracy jest pokazanie, że za pomocą metod uczenia maszynowego można skutecznie badać jakość otrzymywanych w produkcji odlewów za pomocą analizy zdjęć mikrostruktury oraz wartości parametrów mechanicznych odlewów.

Natomiast celem pobocznym jest zaprojektowanie, a następnie zaimplementowanie platformy, za pomocą której będzie można przebadать skuteczność wszystkich zaimplementowanych algorytmów uczenia maszynowego (a także sieci neuronowych) w ocenie jakości odlewów.

Aby osiągnąć ten rezultat, w pierwszym kroku zaimplementowano platformę, dzięki której możliwe było bezproblemowe przetestowanie kolejnych algorytmów uczenia maszynowego. Następnie wykonano przegląd dostępnej literatury w celu rozeznania się, w jaki sposób podchodzi się do zagadnienia oceny jakości odlewów za pomocą uczenia maszynowego. Jak się niestety okazało, nie ma zbyt wielu dostępnych źródeł, które w pełni spełniałyby założenia tego projektu. Dlatego po przeglądzie zebrano odpowiednie dane uczące oraz przeprowadzono na nich proces wykrywania i korygowania błędnych instancji. Następnym krokiem było już zastosowanie najbardziej uniwersalnych algorytmów uczenia maszynowego w celu zdiagnozowania, które z nich mają największą skuteczność dla tak postawionego problemu. Ostatnim krokiem było sformułowanie wniosków oraz wskazanie najbardziej skutecznego podejścia w celu oceny jakości odlewów.

### 1.3. Zawartość pracy

Rozdział 2 zawiera przegląd prac naukowych, które wpłynęły na wybór metod w tej pracy. Zostały w nim przedstawione dosyć szeroko podejścia stosowane na przestrzeni lat w celu oceny jakości odlewów i innych zadaniach blisko powiązanych.

W rozdziale 3 została przedstawiona charakterystyka uczenia maszynowego oraz sieci neuronowych, różne typy reprezentacji wiedzy, metody uczenia się i wiele innych aspektów powiązanych z tą tematyką.

W rozdziale 4 pokazano, w jaki sposób uzyskano dane oraz jak były one przekształcane, aby wydobyć z nich jak najwięcej informacji.

Wszystkie przeprowadzone testy i badania wraz z wynikami zostały omówione w rozdziale 5.

W ostatnim rozdziale 6 zostały zawarte podsumowania badań, wnioski, jakie można było z nich wyciągnąć. Zostały również zaproponowane dalsze wymagane prace w celu udoskonalenia otrzymanych wyników.


## 2. Stan badań

### 2.1. Powiązane prace – zarys historyczny

#### 2.1.1. Predykcja wartości liczby ferrytowej

Przewidywanie własności mechanicznych produktów odlewniczych za pomocą metod uczenia maszynowego ma niemal tak długą historię, jak sama dziedzina uczenia maszynowego. Już w jednej z pierwszych prac naukowych na ten temat [3] (1985) mówiono o tym, że przyszłe techniki predykcyjne będą opierać się raczej na wyrażeniach matematycznych czy sztucznej inteligencji niż na diagramach. Ówczesnie do przewidywania fazy mikrostruktury spoiny metalu wykorzystywano właśnie diagramy (rys. 1), lecz jak łatwo się domyślić, jest to podejście mało praktyczne. Stąd nacisk na wykorzystywanie jak najbardziej wszechstronnych wyrażen ilościowych do przewidywania mikrostruktury jako funkcji m.in. składu.

Następnym krokiem było opracowanie modelu półempirycznego w celu powiązania składu metalu spoiny z liczbą ferrytową (zwaną dalej FN), czyli miarą oznaczania zawartości ferrytu w stali nierdzewnej. Dlaczego jest to istotne? Jak wskazano w pracy [7] wielkość FN określa właściwości metalu takie, jak wytrzymałość, twardość, odporność na korozję i inne (jej poziom powinien wynosić 3-7%, ponieważ niski poziom ferrytu może prowadzić do pęknięć [4, 6], z drugiej strony wysoki poziom ferrytu prowadzi do niższej odporności na korozję [6]). W pracy Babu i in. [5] (1997) przedstawiono wyniki aproksymacji punktowej, która dopasowuje model do prognoz zgodnych z obserwacjami eksperymentalnymi. Stwierdzono w niej, iż ogólna dokładność badanego modelu jest porównywalna do tej z diagramu WRC 1992 (czyli najnowocześniejszej ówczesnie metody – przyp. aut.), który powstał w ten sposób, iż skład stopu jest konwertowany do dwóch czynników – ekwiwalentu chromu ( $Cr_{eq}$ , wzór 1) oraz ekwiwalentu niklu ( $Ni_{eq}$ , wzór 2). Wynika to z tego, iż ten pierwszy zawiera elementy, które wpływają na mikrostrukturę w ten sam sposób jak chrom (tj. stabilizatory ferrytu), natomiast ten drugi zawiera elementy, które wpływają na mikrostrukturę w ten sam sposób, jak nikiel (tj. stabilizatory austenitu). Następnie z diagramu można odczytać poziom ferrytu, który jest przedstawiony jako funkcja od ekwiwalentów chromu i niklu. Jak stwierdzają autorzy [5], zaletą aproksymacji punktowej w porównaniu z diagramem WRC 1992 jest jego zdolność do uwzględniania wpływu innych pierwiastków stopowych oraz łatwość ekstrapolacji do wyższych wartości  $Cr_{eq}$  i  $Ni_{eq}$  (WRC 1992 jest pod tym względem mocno ograniczone, co widać na rysunku 2).



Rys. 2.1. Przykładowy schemat do wyznaczania ferrytu  $\delta$  z granicami składu (De-Long, 1973)


Równania na  $Cr_{eq}$  i  $Ni_{eq}$  są następujące:

$$Cr_{eq} = Cr + Mo + 0.7Nb \quad (2.1)$$

$$Ni_{eq} = Ni + 35C + 20N + 0.25Cu \quad (2.2)$$

gdzie symbole pierwiastków przedstawiają procent wagi każdego pierwiastka. W kolejnej pracy [7] dotyczącej predykcji FN ci sami autorzy wykorzystali sieć neuronową, która na wejściu przyjmowała procent wagowy 13 pierwiastków (Fe, Cr, Ni, C, N, Mo, Mn, Si, Cu, Ti, Nb, V i Co), czyli warstwa z 13 neuronami, następnie warstwa ukryta z sześcioma neuronami, natomiast na wyjściu był pojedynczy neuron, który zwracał liczbę ferrytową (rys. 3).


Wyniki zostały przedstawione w [8] i jak się okazało, testowana sieć zwracała lepsze wyniki od jakichkolwiek dotychczasowych podejść z błędem RMS mniejszym o 50% od poprzedniej najlepszej metody. W ostatnim przytoczonym artykule dotyczącym predykcji FN [9] również zastosowano sieć neuronową, a konkretnie bayesowską sieć neuronową (BNN). Na wejściu mamy taką samą warstwę, jak w poprzedniej pracy, natomiast tutaj jest więcej neuronów w warstwie ukrytej. Poprawa wyników względem poprzedniej pracy wynosi około 15% (błąd RMS) testując na niezależnym zbiorze danych nieużywanych w szkoleniu.



Rys. 2.2. Diagram WRC 1992 (Kotecki &amp; Siewert, 1992)

### 2.1.2. Predykcja własności mechanicznych odlewów

Początki rozwoju i przetwarzania materiałów nie były łatwe. Mimo wielu przeprowadzonych badań naukowych nad materiałami wciąż pozostaje wiele problemów, w przypadku których brakuje metod ilościowych. Tyczy się to głównie predykcji takich parametrów konstrukcyjnych jak wytrzymałość na rozciąganie, trwałość, twardość itp. Pierwsze badania dotyczące własności mechanicznych odlewów przyjmujące podejście ilościowe brały pod uwagę szczegółowy skład chemiczny oraz takie parametry jak rekrytalizacja, proces starzenia, zakres pracy na zimno, temperatura badania czy szybkość odkształcania [10, 11]. W obydwu tych pracach zastosowano sieci neuronowe oraz uzasadniono, że modele matematyczne sobie nie radzą z wymienionymi wyżej parametrami. Standardowo zastosowano sieć, w której na wejściu podawano procent wagowy pierwiastków w badanym materiale. Jedną z głównych własności mechanicznych jest wytrzymałość na rozciąganie (ang. ultimate tensile strength, UTS), która jest badana od wielu lat. Po fazie odlewu inżynierowie wykorzystują w swoich obliczeniach tę i inne wartości w celu obliczenia odkształcania się, funkcji przyłożonego obciążenia, czasu i wiele innych. Jest ona jednym z ważniejszych czynników do uwzględnienia, gdyż niewystarczająca wartość wytrzymałości może mieć fatalne skutki (jak np. zawalenie się konstrukcji). Innym powodem może być to, iż jedynym sposobem, aby zbadać wartość tej wytrzymałości trzeba przeprowadzić badania niszczące, co powoduje wzrost kosztów produkcji [1]. Jednym ze sposobów analizy wartości UTS jest predykcja za pomocą wartości różnych właściwości odlewu. W przywołanej wcześniej pracy [1] oraz [12] są to



Rys. 2.3. Model sieci neuronowej ORFN (Vitek, 2003)

skład chemiczny, rozmiar odlewu, prędkość chłodzenia, obróbka termiczna. Mając dane w postaci CSV (wartości rozdzielone przecinkiem, od ang. comma-separated values) można skorzystać z klasycznych metod klasyfikacji statystycznej, jak klasyfikacja liniowa, K-najbliższych sąsiadów, drzewa decyzyjne, czy sieci bayesowskie [2]. W przytoczonej pracy skupiono się na sieciach bayesowskich. Wyniki są optymistyczne: dokładność na poziomie ponad 82% oraz błędy MAE (średni błąd bezwzględny, od ang. mean absolute error) oraz MSE (średni błąd kwadratowy, od ang. mean square error) na poziomie odpowiednio 0.2 oraz 0.35. Inne przetestowane metody w tym artykule to KNN (k najbliższych sąsiadów, od ang. k-Nearest Neighbors) oraz ANN (sztuczne sieci neuronowe, od ang. artificial neural networks), które osiągnęły podobne, aczkolwiek nieco gorsze wyniki. Wytrzymałość na rozciąganie można przewidzieć na podstawie dwóch różnych źródeł danych wejściowych [13]: 1) skład chemiczny metalu oraz zmienne procesu walcowania, jak temperatura, czy przebieg; 2) dane na temat mikrostruktury. W pracy tej jako dane wejściowe użyto skład chemiczny, specyfikacje geometryczne oraz zmienne dotyczące procesu rolowania, natomiast modelem wykorzystanym do predykcji wartości wytrzymałości na rozciąganie była ponownie bayesowska sieć neuronowa. Sieć ta składała się z jednej warstwy ukrytej, która z kolei składała się z siedmiu neuronów. Jak stwierdzają autorzy, sieć BNN lepiej się sprawdza w tym celu od tradycyjnych sieci neuronowych, a to ze względu na wyższą odporność na nadmierne dopasowanie danych (overfitting), szczególnie w przypadku, gdy ilość danych jest znacznie ograniczona i nie mamy możliwości zgromadzenia dużej ilości wysokiej jakości danych. Bardzo podobne podejście zastosowano w pracy [19], gdzie użyto sieci neuronowej, a na jej wejściu podawano 20 zmiennych, takich jak skład

chemiczny, warunki obróbki cieplnej czy temperatura badania. W ten sposób uzyskano 93% wartości współczynnika R-kwadrat dla YS oraz UTS.





## 3. Przykłady elementów pracy dyplomowej

### 3.1. Liczba

Pakiet `siunitx` zadba o to, by liczba została poprawnie sformatowana:

1 234 567 890,098 765 432 1

### 3.2. Rysunek

Pakiet `subcaption` pozwala na umieszczanie w podpisie rysunku odnośników do „podilustracji”:

A

(a)

B

(b)

**Rys. 3.1.** Przykład użycia `\subcaption`: (a) litera A, (b) litera B.

### 3.3. Tabela

Pakiet `threeparttable` umożliwia dodanie do tabeli adnotacji:

**Tabela 3.1.** Przykład tabeli

Nagłówek <sup>a</sup>
Tekst 1
Tekst 2

<sup>a</sup> Jakiś komentarz...

### 3.4. Wzory matematyczne

Czasem zachodzi potrzeba wytłumaczenia znaczenia symboli użytych w równaniu. Można to zrobić z użyciem zdefiniowanego na potrzeby niniejszej klasy środowiska `eqwhere`.

$$E = mc^2 \tag{3.1}$$

gdzie

$m$  – masa

$c$  – prędkość światła w próżni

Odległość półpauzy od lewego marginesu należy dobrać pod kątem najdłuższego symbolu (bądź listy symboli) poprzez odpowiednie ustawienie parametru tego środowiska (domyślnie: 2 cm).

## 4. Przykłady elementów pracy dyplomowej

### 4.1. Liczba

Pakiet `siunitx` zadba o to, by liczba została poprawnie sformatowana:

1 234 567 890,098 765 432 1

### 4.2. Rysunek

Pakiet `subcaption` pozwala na umieszczanie w podpisie rysunku odnośników do „podilustracji”:

A

(a)

B

(b)

**Rys. 4.1.** Przykład użycia `\subcaption`: (a) litera A, (b) litera B.

### 4.3. Tabela

Pakiet `threeparttable` umożliwia dodanie do tabeli adnotacji:

**Tabela 4.1.** Przykład tabeli

Nagłówek <sup>a</sup>
Tekst 1
Tekst 2

<sup>a</sup> Jakiś komentarz...

## 4.4. Wzory matematyczne

Czasem zachodzi potrzeba wytłumaczenia znaczenia symboli użytych w równaniu. Można to zrobić z użyciem zdefiniowanego na potrzeby niniejszej klasy środowiska `eqwhere`.

$$E = mc^2 \tag{4.1}$$

gdzie

$m$  – masa

$c$  – prędkość światła w próżni

Odległość półpauzy od lewego marginesu należy dobrać pod kątem najdłuższego symbolu (bądź listy symboli) poprzez odpowiednie ustawienie parametru tego środowiska (domyślnie: 2 cm).

## 5. Przykłady elementów pracy dyplomowej

### 5.1. Liczba

Pakiet `siunitx` zadba o to, by liczba została poprawnie sformatowana:

1 234 567 890,098 765 432 1

### 5.2. Rysunek

Pakiet `subcaption` pozwala na umieszczanie w podpisie rysunku odnośników do „podilustracji”:

A

(a)

B

(b)

**Rys. 5.1.** Przykład użycia `\subcaption`: (a) litera A, (b) litera B.

### 5.3. Tabela

Pakiet `threeparttable` umożliwia dodanie do tabeli adnotacji:

**Tabela 5.1.** Przykład tabeli

Nagłówek <sup>a</sup>
Tekst 1
Tekst 2

<sup>a</sup> Jakiś komentarz...

## 5.4. Wzory matematyczne

Czasem zachodzi potrzeba wytłumaczenia znaczenia symboli użytych w równaniu. Można to zrobić z użyciem zdefiniowanego na potrzeby niniejszej klasy środowiska `eqwhere`.

$$E = mc^2 \tag{5.1}$$

gdzie

$m$  – masa

$c$  – prędkość światła w próżni

Odległość półpauzy od lewego marginesu należy dobrać pod kątem najdłuższego symbolu (bądź listy symboli) poprzez odpowiednie ustawienie parametru tego środowiska (domyślnie: 2 cm).

## 6. Przykłady elementów pracy dyplomowej

### 6.1. Liczba

Pakiet `siunitx` zadba o to, by liczba została poprawnie sformatowana:

1 234 567 890,098 765 432 1

### 6.2. Rysunek

Pakiet `subcaption` pozwala na umieszczanie w podpisie rysunku odnośników do „podilustracji”:

A

(a)

B

(b)

**Rys. 6.1.** Przykład użycia `\subcaption`: (a) litera A, (b) litera B.

### 6.3. Tabela

Pakiet `threeparttable` umożliwia dodanie do tabeli adnotacji:

**Tabela 6.1.** Przykład tabeli

Nagłówek <sup>a</sup>
Tekst 1
Tekst 2

<sup>a</sup> Jakiś komentarz...

## 6.4. Wzory matematyczne

Czasem zachodzi potrzeba wytłumaczenia znaczenia symboli użytych w równaniu. Można to zrobić z użyciem zdefiniowanego na potrzeby niniejszej klasy środowiska `eqwhere`.

$$E = mc^2 \tag{6.1}$$

gdzie

$m$  – masa

$c$  – prędkość światła w próżni

Odległość półpauzy od lewego marginesu należy dobrać pod kątem najdłuższego symbolu (bądź listy symboli) poprzez odpowiednie ustawienie parametru tego środowiska (domyślnie: 2 cm).